

CDP专项优化

DSL 自然语言查询的方案


CDP Agent --- 陈国荣

一、背景

本文围绕 CDP 当前用户数据、行为数据处理链路中的性能瓶颈与表结构治理问题，梳理现状、明确近期优化方向，并提出 ID Mapping 长期演进思路。

二、当前CDP模式

当前 CDP 的数据来源主要包括用户导入、表单提交以及外部数据请求。



1. 用户数据

- 对用户数据进行格式校验。
 - 参与 ID Mapping 用户识别流程，计算并生成用户 UID。
- 将更新后的用户数据写入 MySQL。
- 推送用户创建、更新等事件，并同步 custom field 等相关行为数据。
 - 通过 Flink CDC 监听用户表变更。
 - 将数据写入 Doris，落入 ods_omniuser_jing_omni_users 表。

2. 行为数据

- 行为数据上报后进入 Flume。

- 完成格式校验后，将行为数据推送至 Kafka。
- Event Service 消费 Kafka 中的行为数据。
- 校验行为元数据。
- 完成行为处理链路编排。
- 根据身份字段判断数据类型，分别进入实例化行为或匿名行为处理流程。
- 完成行为数据组装。
- 兼容历史行为数据格式。
- 将处理后的行为数据推送至 Kafka。
- 由多个 Flink 任务消费 Kafka 数据。
- 最终写入 Doris 表 ods_event_action_data 和 ES 表，并推送至业务 Kafka。

三、当前优化方向

1. 治理 Doris 行为表 ods_event_action_data

- 优化行为表合并逻辑，将当前的读时合并调整为写时合并，降低查询阶段的计算压力。
- 重新规划分区策略：当前行为表按租户分区，因租户数据量差异较大，容易造成桶倾斜；建议调整为按行为发生时间分区。
- 重新评估分桶数：当前行为数据约 47 亿条、数据量约 1 TB，仅配置 5 个分桶，难以支撑现有数据规模和查询性能要求。
- 优化行为属性存储结构：当前行为属性集中存放在 extra_data 这一 JSON 字段中，查询效率较低；建议新增 extra_data_v2 (VARIANT 类型) 以提升行为属性查询性能。
- 针对KA租户或高频特殊属性，在ods层搭建flink进行分表操作
- KA租户属性打平至行为表，形成大宽表，以提升特定场景下的查询效率。

2. 治理 Doris 用户表 ods_omniuser_jing_omni_users

- 优化当前用户表的写时合并能力，提升数据写入与查询的整体效率。
- 重新评估默认分桶数：当前默认 5 个分桶，难以满足用户表持续增长后的性能要求。
- 为部分核心字段补充倒排索引，提升检索效率 --- 待处理
- 梳理用户表中的大 JSON 字段，重点关注以下字段：
- group_ids：静态群组 ID --- 待处理
- tag_ids：标签 ID。 --- 待处理
- channel_user_datas：渠道数据。 --- 待处理
- latest_source_data：来源数据。 --- 待处理
- custom_field：自定义字段数据，已改造为高表结构。 ---- 已解决


3. 提升 ID Mapping 分布式横向扩展能力

- 当前 ID Mapping 采用 Java 开发，对外提供用户识别接口并参与业务侧用户识别流程；随着请求量增长，存在性能与 QPS 瓶颈，需要提升服务的分布式横向扩展能力。
- 通过代理（如类似nginx 做svc的代理）IDmapping服务，做分布式操作，指定租户进入指定的pod

四、 远期目标

1. 处理IDmapping

- 重构IDmapping、使用flink参与计算的方式，把身份和id写入到redis
- 业务参与用户识别直接查询redis
- 多对象导入通过flink计算后再进入业务



2. 补充筛选器场景

- 扩充多对象查询
- 扩充筛选器筛选场景字段类型

3. 自定义对象关联查询

对接自定义元数据对象

跨对象对象关联寻找关系